Estudio de Técnicas para la Conversión de Datos Categóricos a Numéricos

Autor: Franco Serafini
Tutora: Dra. Andrea Rey

Universidad Nacional de Hurlingham (UNAHUR)

Índice general

Índice de Figures **3**

Índice de Tablas **5**

1. Introducción **11**
1.1. Motivación 11
1.2. Estado del Arte 11
1.3. Conjuntos de Datos 11
1.3.1. Ficha técnica 11
1.3.2. Descripción de las Características 11
1.3.3. Análisis de Calidad y Limpieza de Datos 12

2. Metodología de Codificación Categórica **15**
2.1. Necesidad del Preprocesamiento de Datos Categóricos 15
2.1.1. El concepto de representación numérica en modelos matemáticos 15
2.1.2. El desafió de la naturaleza de los datos y el riesgo del sesgo 15
2.1.3. Algoritmos con soporte categórico nativo vs Transformación 16
2.2. One-Hot Encoding (OHE) 16
2.2.1. Definición Formal 16
2.2.2. Implementación e Impacto en la Dimensionalidad 16
2.3. Count Encoding 17
2.3.1. Mecanica de Transformacion y Definicion Formal 17
2.3.2. Frecuencia Relativa Normalizada 17
2.3.3. Implementación y e Impacto en el Dataset 17

3. Resultados y discusión **19**

4. Conclusiones **21**

Bibliografía **23**

Índice de Figuras

Índice de Tablas

1.1. Ficha técnica del Adult Income Dataset. 11
1.2. Diccionario de datos: tipos, descripciones y análisis de dominios. 12
1.3. Distribución de valores faltantes y estrategia de imputación. 12
1.4. Modificación de la concentración de la moda tras la limpieza. 13

Resumen

Capítulo 1

Introducción

1.1 Motivación

1.2 Estado del Arte

1.3 Conjuntos de Datos

En esta sección se detalla la naturaleza, el origen y la composicion del conjunto de datos utilizado para el presente estudio.

1.3.1 Ficha técnica

El conjunto de datos seleccionados es el *'Adult Income Dataset'*, obtenido del repositorio publico Kaggle [1]. Este *dataset* es una extracción de datos históricos reales provenientes del censo de los Estados Unidos de 1994.

Este estudio aborda un problema de **clasificación binaria supervisada**: predecir si los ingresos anuales de una persona superan los $50.000 dólares. A continuación, se presenta la Tabla 1.1 con las especificaciones generales:

Categoría	Detalle
Fuente	Censo de EE. UU. (1994)
Instancias (Registros)	48,842
Atributos Originales	15 (14 predictores + 1 objetivo)
Tipo de Datos	Mixtos (Numéricos y Categóricos)
Tipo de Problema	Clasificación Binaria Supervisada
Variable Objetivo	Ingresos anuales (*Income*)
Valores de Clase	$\leq$ 50,000 USD (0) / $>$ 50,000 USD (1)

Tabla 1.1: Ficha técnica del Adult Income Dataset.

1.3.2 Descripción de las Características

El *dataset* consta con 14 atributos predictivos que capturan información demográfica y laboral. En la Tabla 1.2 se presenta el diccionario de datos detallados:

[1] Disponible en: `https://www.kaggle.com/datasets/wenruliu/adult-income-dataset`

Atributo	Tipo de Dato	Descripción	Dominio / Cardinalidad
Age	Numérico (Int)	Edad de los individuos.	Rango: 17 a 90 años.
Workclass	Categórico	Sector de empleo.	9 categorías.
Fnlwgt	Numérico (Int)	Peso muestral de la población.	Rango: 12,285 a 1,490,400.
Education	Categórico	Nivel de estudios alcanzado.	16 categorías.
Educational-num	Numérico (Int)	Nivel educativo escalar.	Rango: 1 a 16.
Marital-status	Categórico	Estado civil.	7 categorías.
Occupation	Categórico	Especialidad laboral.	15 categorías.
Relationship	Categórico	Rol dentro del núcleo familiar.	6 categorías.
Race	Categórico	Origen étnico.	5 categorías.
Gender	Categórico	Género biológico.	2 categorías.
Capital-gain	Numérico (Int)	Utilidades financieras.	Rango: 0 a 99,999.
Capital-loss	Numérico (Int)	Pérdidas financieras.	Rango: 0 a 4,356.
Hours-per-week	Numérico (Int)	Carga horaria semanal.	Rango: 1 a 99 horas.
Native-country	Categórico	País de procedencia.	42 categorías.
Income (Target)	**Categórico**	**Variable objetivo.**	**2 niveles (0 y 1).**

Tabla 1.2: Diccionario de datos: tipos, descripciones y análisis de dominios.

1.3.3 Análisis de Calidad y Limpieza de Datos

Previo a la aplicación de las técnicas de *encoding*, se procede a realizar la limpieza de los datos. El *Adult Income Dataset* contiene ruidos e inconsistencias (valores '?' y duplicados) que deben tratarse para asegurar la robustez de los modelos.

Identificación y Cuantificación de los Valores faltantes

Durante la exploración inicial, se identificó que el conjunto de datos emplea el carácter especial `'?'` para representar información desconocida. Mediante un análisis de frecuencias, se determinó que el impacto de estos valores se concentra exclusivamente en tres variables categóricas, como se detalla en la Tabla 1.3:

Atributo	Cantidad de '?'	Porcentaje	Moda (Valor para imputación)
Workclass	2,799	5.73 %	Private
Occupation	2,809	5.75 %	Prof-specialty
Native-country	857	1.75 %	United-States

Tabla 1.3: Distribución de valores faltantes y estrategia de imputación.

Impacto de la Imputación y Análisis de Distribución

Se optó por una **imputación por moda**, sustituyendo el carácter `'?'` por el valor más frecuente. Si bien esto preserva el tamaño de la muestra, altera la distribución original. En la Tabla 1.4 se observa cómo se incrementó la concentración en las categorías dominantes:

Atributo	Categoría (Moda)	% Original	% Post-Imputación	Variación
Workclass	Private	69.41 %	75.15 %	+5.74 %
Occupation	Prof-specialty	12.63 %	18.38 %	+5.75 %
Native-country	United-States	89.74 %	91.49 %	+1.75 %

Tabla 1.4: Modificación de la concentración de la moda tras la limpieza.

Riesgos Identificados: Esta técnica acentúa el sesgo hacia las clases mayoritarias. En el caso de *Occupation*, la moda creció casi un 50 % respecto a su valor original, lo que podría introducir correlaciones artificiales que los modelos de *Machine Learning* podrían sobreajustar (*overfitting*).

Eliminación de Registros Duplicados

Se detectaron y eliminaron **52 registros duplicados**, resultado en un *dataset* final de **48.790 registros**.

Consolidación del Dataset

Tras el procesamiento, se realizo un reajuste del indice y se verifico la consistencia de los tipos de datos: variables numéricas (*int64*) y categóricas (*str*). Los datos limpios se exportaron al archivo `adult_limpio.csv` para asegurar que todos los experimentos de *encoding* partan de la misma base de información.

Capítulo 2

Metodología de Codificación Categórica

En este capitulo se describen las técnicas de transformación de datos implementadas para convertir las variables cualitativas del *Adult Income Dataset* en representaciones numéricas. Este proceso es fundamental para permitir la comparación de rendimiento entre diversos algoritmos de Aprendizaje Automático.

2.1 Necesidad del Preprocesamiento de Datos Categóricos

El éxito de los modelos de *Machine Learning* (ML) y *Deep Learning* (DL) reside en su capacidad para identificar patrones mediante herramientas estadísticas y matemáticas.

2.1.1 El concepto de representación numérica en modelos matemáticos

La mayoría de los algoritmos de Aprendizaje Automático, incluyendo las Redes Neuronales, la Regresión Logística y las Maquinas de Soporte Vectorial (SVM), son funciones matemáticas que operan exclusivamente sobre **tensores numéricos**. En estas estructuras, cada atributo de entrada debe ser una magnitud escalar que permita realizar operaciones de álgebra lineal, como el calculo de productos punto, o de calculo diferencial, como la actualización de pesos mediante la gradiente descendente. En este contexto, las etiquetas de texto como `'Private'` (perteneciente a la variable *workclass*) o `'China'` (de *native-country*) carecen de valor operativo directo para los cálculos internos del algoritmo. Por lo tanto, se debe establecer una función de transformación $\phi : \mathcal{C} \to \mathbb{R}^n$ que proyecte el espacio de categorías cualitativas en un espacio vectorial numérico. Esta representación vectorial permite que tanto los modelos de Aprendizaje Automático como los de Aprendizaje Profundo puedan procesar y extraer patrones de la información demográfica y laboral del censo.

2.1.2 El desafió de la naturaleza de los datos y el riesgo del sesgo

Una solución trivial seria el *Label Encoding*, que asigna un numero entero arbitrario a cada categoría. No obstante, para atributos nominales como *occupation* o *native-country*, esta técnica introduce un **sesgo de orden natural inexistente**. Si se utilizara una codificación entera simple, un modelo de ML (especialmente aquellos basados en distancias o pesos) interpretaría erróneamente que una categoría con valor 3 es "superior.º "mas distante.ª una con valor 1. Este orden artificial distorsiona la realidad de los datos nominales y puede degradar significativamente la precisión de los modelos.

2.1.3 Algoritmos con soporte categórico nativo vs Transformación

Es importante destacar que existen algoritmos basados en arboles de decisión (como *Random Forest*) o *XGBoost*) que pueden manejar atributos categóricos mediante lógicas en sus nodos. Sin embargo, para realizar un estudio comparativo, o para utilizar arquitecturas de DL, se debe realizar una estandarización mediante técnicas de *encoding*. Este trabajo explora tres enfoques distintos para resolver este desafió: *One-Hot Encoding*, *Count Encoding* y *Hashing Encoding*.

2.2 One-Hot Encoding (OHE)

El *One-Hot Encoding* es una de las técnicas de transformación mas utilizadas para el tratamiento de variables categóricas nominales, debido a su sencillez y compatibilidad con la mayoría de los algoritmos de aprendizaje automático. Su principio se basa en la eliminación de cualquier relación de orden mediante la binarización de los niveles de cada atributo.

2.2.1 Definición Formal

Matemáticamente, el *One-Hot Encoding* puede definirse como una función de mapeo ϕ que proyecta un nivel categórico en un espacio vectorial binario de dimensión k, donde k es la cardinalidad del atributo (número de niveles únicos).

Sea $\mathcal{C} = \{c_1, c_2, \ldots, c_k\}$ el conjunto de todos los niveles posibles de una variable categórica. La función $\phi : \mathcal{C} \to \{0,1\}^k$ asigna a cada categoría c_i un vector canónico $\mathbf{e}_i \in \mathbb{R}^k$:

$$\phi(c_i) = \mathbf{e}_i = (0, \ldots, 0, \underbrace{1}_{i\text{-ésima pos.}}, 0, \ldots, 0) \tag{2.1}$$

De esta manera, para cualquier instancia del conjunto de datos que pertenezca a la categoría c_i, la representación resultante es un vector de longitud k donde todas sus componentes son nulas, a excepción de la posición i, que toma el valor unitario. Esta propiedad garantiza que todos los vectores resultantes sean ortogonales entre sí, asegurando que el modelo no interprete cercanías o jerarquías espaciales erróneas entre etiquetas nominales.

2.2.2 Implementación e Impacto en la Dimensionalidad

En este trabajo, se implementó la función de OHE sobre las 8 variables categóricas del *dataset*. La aplicación de esta técnica generó una **explosión de dimensionalidad**.

El *dataset* original, que contaba con 14 atributos predictivos, se expandió a un total de **106 columnas** tras la codificación. El tamaño final del espacio de características D_{final} tras el proceso de binarización puede calcularse como:

$$D_{final} = D_{num} + \sum_{j=1}^{N} k_j \tag{2.2}$$

Donde D_{num} representa las variables numéricas originales y k_j la cardinalidad de la j-ésima variable categórica. En nuestro caso, este incremento exponencial se atribuye principalmente a variables como *native-country* ($k = 41$) y *occupation* ($k = 14$). Como resultado, se obtiene una matriz de diseño altamente dispersa (*sparse matrix*), lo cual aumenta los requerimientos de memoria y la complejidad computacional para los algoritmos de aprendizaje posteriores.

2.3 Count Encoding

El *Count Encoding* es una técnica de transformación que captura la importancia estadística de cada categoría dentro del conjunto de datos. A diferencia del OHE, este método no expande el espacio de características, manteniendo una correspondencia de 1:1 entre las variables originales y las transformadas.

2.3.1 Mecanica de Transformacion y Definicion Formal

La técnica consiste en reemplazar cada etiqueta categórica por el numero total de apariciones (frecuencia absoluta) de dicha etiqueta en el *dataset*. Sea X un atributo categórico y $\mathcal{C} = \{c_1, c_2 \ldots, c_k\}$ el conjunto de sus niveles. Definimos la función de transformación T como:

$$T(c_i) = \sum_{j=1}^{m} \mathbb{I}(x_j = c_i) \tag{2.3}$$

Donde m es el numero total de registros e $\mathbb{I}$ es la función indicatriz que toma el valor 1 si el registro x_j coincide con la categoría c_i, y 0 en caso contrario.

2.3.2 Frecuencia Relativa Normalizada

Se implemento una variante de **Count Encoding Normalizado**, la cual consiste en una función de transformación T_{norm} que se define como la probabilidad empírica de la categoría:

$$T_{norm}(c_i) = \frac{\sum_{j=1}^{m} \mathbb{I}(x_j = c_i)}{m} \tag{2.4}$$

Donde m es el tamaño total del *dataset*. El resultado es un espacio de características donde cada valor esta acotado en el intervalo $[0, 1]$.

2.3.3 Implementación y e Impacto en el Dataset

El impacto principal de esta técnica en el *Adult Income Dataset* fue la **preservación de la dimensionalidad original**. Tras la transformación, el dataset mantuvo sus **14 atributos predictivos**.

Capítulo 3

Resultados y discusión

Capítulo 4

Conclusiones

Bibliografía