Estudio de Técnicas para la Conversión de Datos Categóricos a Numéricos

Autor: Franco Serafini
Tutora: Dra. Andrea Rey

Universidad Nacional de Hurlingham (UNAHUR)

Índice general

Índice de Figures **3**

Índice de Tablas **5**

1. Introducción **11**

1.1. Motivación 11

1.2. Estado del Arte 11

1.3. Conjuntos de Datos 11

1.3.1. Ficha técnica 11

1.3.2. Descripción de las Características 11

1.3.3. Análisis de Calidad y Limpieza de Datos 12

1.3.4. Identificacion y Cuantificacion de los Valores faltantes 12

1.3.5. Estrategias de Depuración Implementadas 12

2. Metodología **15**

3. Resultados y discusión **17**

4. Conclusiones **19**

Bibliografía **21**

Índice de Figuras

Índice de Tablas

1.1. Ficha técnica del Adult Income Dataset. 11
1.2. Diccionario de datos: tipos, descripciones y análisis de dominios. 12
1.3. Distribución de valores faltantes y estrategia de imputación. 12

Resumen

Capítulo 1

Introducción

1.1 Motivación

1.2 Estado del Arte

1.3 Conjuntos de Datos

En esta sección se detalla la naturaleza, el origen y la composicion del conjunto de datos utilizado para el presente estudio.

1.3.1 Ficha técnica

El conjunto de datos seleccionados es el *'Adult Income Dataset'*, obtenido del repositorio publico Kaggle [1]. Este *dataset* es una extracción de datos históricos reales provenientes del censo de los Estados Unidos de 1994.

Este estudio aborda un problema de **clasificación binaria supervisada**: predecir si los ingresos anuales de una persona superan los $50.000 dólares. A continuación, se presenta la Tabla 1.1 con las especificaciones generales:

Categoría	Detalle
Fuente	Censo de EE. UU. (1994)
Instancias (Registros)	48,842
Atributos Originales	15 (14 predictores + 1 objetivo)
Tipo de Datos	Mixtos (Numéricos y Categóricos)
Tipo de Problema	Clasificación Binaria Supervisada
Variable Objetivo	Ingresos anuales (*Income*)
Valores de Clase	$\leq$ 50,000 USD (0) / $>$ 50,000 USD (1)

Tabla 1.1: Ficha técnica del Adult Income Dataset.

1.3.2 Descripción de las Características

El *dataset* consta con 14 atributos predictivos que capturan información demográfica y laboral. En la Tabla 1.2 se presenta el diccionario de datos detallados:

[1] Disponible en: `https://www.kaggle.com/datasets/wenruliu/adult-income-dataset`

Atributo	Tipo de Dato	Descripción	Dominio / Cardinalidad
Age	Numérico (Int)	Edad de los individuos.	Rango: 17 a 90 años.
Workclass	Categórico	Sector de empleo.	9 categorías.
Fnlwgt	Numérico (Int)	Peso muestral de la población.	Rango: 12,285 a 1,490,400.
Education	Categórico	Nivel de estudios alcanzado.	16 categorías.
Educational-num	Numérico (Int)	Nivel educativo escalar.	Rango: 1 a 16.
Marital-status	Categórico	Estado civil.	7 categorías.
Occupation	Categórico	Especialidad laboral.	15 categorías.
Relationship	Categórico	Rol dentro del núcleo familiar.	6 categorías.
Race	Categórico	Origen étnico.	5 categorías.
Gender	Categórico	Género biológico.	2 categorías.
Capital-gain	Numérico (Int)	Utilidades financieras.	Rango: 0 a 99,999.
Capital-loss	Numérico (Int)	Pérdidas financieras.	Rango: 0 a 4,356.
Hours-per-week	Numérico (Int)	Carga horaria semanal.	Rango: 1 a 99 horas.
Native-country	Categórico	País de procedencia.	42 categorías.
Income (Target)	**Categórico**	**Variable objetivo.**	**2 niveles (0 y 1).**

Tabla 1.2: Diccionario de datos: tipos, descripciones y análisis de dominios.

1.3.3 Análisis de Calidad y Limpieza de Datos

Previo a la aplicación de las técnicas de *encoding*, se procede a realizar la limpieza de los datos. El *Adult Income Dataset* contiene ruidos e inconsistencias (valores '?' y duplicados) que deben tratarse.

1.3.4 Identificación y Cuantificación de los Valores faltantes

Durante la exploración inicial, se identifico que el conjunto de datos emplea el carácter especial `'?'` para representar información desconocida. Mediante un análisis de frecuencias, se determino que el impacto de estos valores se concentra exclusivamente en tres variables categóricas, como se detalla en la Tabla 1.3:

Atributo	Cantidad de '?'	Porcentaje	Moda (Valor para imputación)
Workclass	2,799	5.73 %	Private
Occupation	2,809	5.75 %	Prof-specialty
Native-country	857	1.75 %	United-States

Tabla 1.3: Distribución de valores faltantes y estrategia de imputación.

1.3.5 Estrategias de Depuración Implementadas

Para garantizar la integridad de los datos, se realizaron las siguientes acciones de depuración e imputación:

1. **Imputación por Moda:** En lugar de descartar registros, se opto por sustituir el caracter `'?'` por el valor mas frecuente de cada columna. Gracias a esto preservamos el tamaño de la muestra original.

2. **Eliminación de Registros Duplicados:** Se detectaron y eliminaron **52 registros duplicados**, resultado en un *dataset* final de **48.789 registros**.

3. **Consolidación del Dataset:** Tras el procesamiento, se realizo un reajuste del indice y se verifico la consistencia de los tipos de datos: variables numéricas (*int64*) y categóricas (*str*). Los datos limpios se exportaron al archivo `adult_limpio.csv` para asegurar que todos los experimentos de *encoding* partan de la misma base de información.

Capítulo 2

Metodología

Capítulo 3

Resultados y discusión

Capítulo 4

Conclusiones

Bibliografía