Estudio de Técnicas para la Conversión de Datos Categóricos a Numéricos

Autor: Franco Serafini
Tutora: Dra. Andrea Rey

Universidad Nacional de Hurlingham (UNAHUR)

Índice general

Índice de Figures **3**

Índice de Tablas **5**

1. Introducción **11**
1.1. Motivación . . . 11
1.2. Estado del Arte . . . 11
1.3. Conjuntos de Datos . . . 11
1.3.1. Ficha técnica . . . 11
1.3.2. Descripción de las Características . . . 11
1.3.3. Análisis de Calidad y Limpieza de Datos . . . 12

2. Metodología de Codificación Categórica **15**
2.1. Necesidad del Preprocesamiento de Datos Categóricos . . . 15
2.1.1. El concepto de representación numérica en modelos matemáticos . . . 15
2.1.2. El desafió de la naturaleza de los datos y el riesgo del sesgo . . . 15
2.1.3. Algoritmos con soporte categórico nativo vs Transformación . . . 16
2.2. One-Hot Encoding (OHE) . . . 16
2.2.1. Definición Formal . . . 16
2.2.2. Implementación e Impacto en la Dimensionalidad . . . 16
2.3. Count Encoding . . . 17
2.3.1. Mecánica de Transformación y Definición Formal . . . 17
2.3.2. Frecuencia Relativa Normalizada . . . 17
2.3.3. Implementación y e Impacto en el Dataset . . . 17
2.4. Hashing Encoding . . . 17
2.4.1. Definición Formal y Proceso de Hash (MurmurHash3) . . . 17
2.4.2. Implementación Experimental e Impacto en la Dimensionalidad . . . 18
2.4.3. Análisis de Riesgos: El Fenómeno de la Colisión . . . 19
2.4.4. Análisis Comparativo de las Técnicas de Codificación . . . 19

3. Resultados y discusión **21**

4. Conclusiones **23**

Bibliografía **25**

Índice de Figuras

Índice de Tablas

1.1. Ficha técnica del Adult Income Dataset. 11
1.2. Diccionario de datos: tipos, descripciones y análisis de dominios. 12
1.3. Distribución de valores faltantes y estrategia de imputación. 12
1.4. Modificación de la concentración de la moda tras la limpieza. 13

2.1. Comparativa del impacto de las técnicas de encoding en la dimensionalidad del dataset Adult Income. 19

Resumen

Capítulo 1

Introducción

1.1 Motivación

1.2 Estado del Arte

1.3 Conjuntos de Datos

En esta sección se detalla la naturaleza, el origen y la composicion del conjunto de datos utilizado para el presente estudio.

1.3.1 Ficha técnica

El conjunto de datos seleccionados es el *'Adult Income Dataset'*, obtenido del repositorio publico Kaggle [1]. Este *dataset* es una extracción de datos históricos reales provenientes del censo de los Estados Unidos de 1994.

Este estudio aborda un problema de **clasificación binaria supervisada**: predecir si los ingresos anuales de una persona superan los $50.000 dólares. A continuación, se presenta la Tabla 1.1 con las especificaciones generales:

Categoría	Detalle
Fuente	Censo de EE. UU. (1994)
Instancias (Registros)	48,842
Atributos Originales	15 (14 predictores + 1 objetivo)
Tipo de Datos	Mixtos (Numéricos y Categóricos)
Tipo de Problema	Clasificación Binaria Supervisada
Variable Objetivo	Ingresos anuales (*Income*)
Valores de Clase	$\leq$ 50,000 USD (0) / $>$ 50,000 USD (1)

Tabla 1.1: Ficha técnica del Adult Income Dataset.

1.3.2 Descripción de las Características

El *dataset* consta con 14 atributos predictivos que capturan información demográfica y laboral. En la Tabla 1.2 se presenta el diccionario de datos detallados:

[1] Disponible en: `https://www.kaggle.com/datasets/wenruliu/adult-income-dataset`

Atributo	Tipo de Dato	Descripción	Dominio / Cardinalidad
Age	Numérico (Int)	Edad de los individuos.	Rango: 17 a 90 años.
Workclass	Categórico	Sector de empleo.	9 categorías.
Fnlwgt	Numérico (Int)	Peso muestral de la población.	Rango: 12,285 a 1,490,400.
Education	Categórico	Nivel de estudios alcanzado.	16 categorías.
Educational-num	Numérico (Int)	Nivel educativo escalar.	Rango: 1 a 16.
Marital-status	Categórico	Estado civil.	7 categorías.
Occupation	Categórico	Especialidad laboral.	15 categorías.
Relationship	Categórico	Rol dentro del núcleo familiar.	6 categorías.
Race	Categórico	Origen étnico.	5 categorías.
Gender	Categórico	Género biológico.	2 categorías.
Capital-gain	Numérico (Int)	Utilidades financieras.	Rango: 0 a 99,999.
Capital-loss	Numérico (Int)	Pérdidas financieras.	Rango: 0 a 4,356.
Hours-per-week	Numérico (Int)	Carga horaria semanal.	Rango: 1 a 99 horas.
Native-country	Categórico	País de procedencia.	42 categorías.
Income (Target)	**Categórico**	**Variable objetivo.**	**2 niveles (0 y 1).**

Tabla 1.2: Diccionario de datos: tipos, descripciones y análisis de dominios.

1.3.3 Análisis de Calidad y Limpieza de Datos

Previo a la aplicación de las técnicas de *encoding*, se procede a realizar la limpieza de los datos. El *Adult Income Dataset* contiene ruidos e inconsistencias (valores '?' y duplicados) que deben tratarse para asegurar la robustez de los modelos.

Identificación y Cuantificación de los Valores faltantes

Durante la exploración inicial, se identificó que el conjunto de datos emplea el carácter especial `'?'` para representar información desconocida. Mediante un análisis de frecuencias, se determinó que el impacto de estos valores se concentra exclusivamente en tres variables categóricas, como se detalla en la Tabla 1.3:

Atributo	Cantidad de '?'	Porcentaje	Moda (Valor para imputación)
Workclass	2,799	5.73 %	Private
Occupation	2,809	5.75 %	Prof-specialty
Native-country	857	1.75 %	United-States

Tabla 1.3: Distribución de valores faltantes y estrategia de imputación.

Impacto de la Imputación y Análisis de Distribución

Se optó por una **imputación por moda**, sustituyendo el carácter `'?'` por el valor más frecuente. Si bien esto preserva el tamaño de la muestra, altera la distribución original. En la Tabla 1.4 se observa cómo se incrementó la concentración en las categorías dominantes:

Atributo	Categoría (Moda)	% Original	% Post-Imputación	Variación
Workclass	Private	69.41 %	75.15 %	+5.74 %
Occupation	Prof-specialty	12.63 %	18.38 %	+5.75 %
Native-country	United-States	89.74 %	91.49 %	+1.75 %

Tabla 1.4: Modificación de la concentración de la moda tras la limpieza.

Riesgos Identificados: Esta técnica acentúa el sesgo hacia las clases mayoritarias. En el caso de *Occupation*, la moda creció casi un 50 % respecto a su valor original, lo que podría introducir correlaciones artificiales que los modelos de *Machine Learning* podrían sobreajustar (*overfitting*).

Eliminación de Registros Duplicados

Se detectaron y eliminaron **52 registros duplicados**, resultado en un *dataset* final de **48.790 registros**.

Consolidación del Dataset

Tras el procesamiento, se realizo un reajuste del indice y se verifico la consistencia de los tipos de datos: variables numéricas (*int64*) y categóricas (*str*). Los datos limpios se exportaron al archivo `adult_limpio.csv` para asegurar que todos los experimentos de *encoding* partan de la misma base de información.

Capítulo 2

Metodología de Codificación Categórica

En este capitulo se describen las técnicas de transformación de datos implementadas para convertir las variables cualitativas del *Adult Income Dataset* en representaciones numéricas. Este proceso es fundamental para permitir la comparación de rendimiento entre diversos algoritmos de Aprendizaje Automático.

2.1 Necesidad del Preprocesamiento de Datos Categóricos

El éxito de los modelos de *Machine Learning* (ML) y *Deep Learning* (DL) reside en su capacidad para identificar patrones mediante herramientas estadísticas y matemáticas.

2.1.1 El concepto de representación numérica en modelos matemáticos

La mayoría de los algoritmos de Aprendizaje Automático, incluyendo las Redes Neuronales, la Regresión Logística y las Maquinas de Soporte Vectorial (SVM), son funciones matemáticas que operan exclusivamente sobre **tensores numéricos**. En estas estructuras, cada atributo de entrada debe ser una magnitud escalar que permita realizar operaciones de álgebra lineal, como el calculo de productos punto, o de calculo diferencial, como la actualización de pesos mediante la gradiente descendente. En este contexto, las etiquetas de texto como `'Private'` (perteneciente a la variable *workclass*) o `'China'` (de *native-country*) carecen de valor operativo directo para los cálculos internos del algoritmo. Por lo tanto, se debe establecer una función de transformación $\phi : \mathcal{C} \to \mathbb{R}^n$ que proyecte el espacio de categorías cualitativas en un espacio vectorial numérico. Esta representación vectorial permite que tanto los modelos de Aprendizaje Automático como los de Aprendizaje Profundo puedan procesar y extraer patrones de la información demográfica y laboral del censo.

2.1.2 El desafió de la naturaleza de los datos y el riesgo del sesgo

Una solución trivial seria el *Label Encoding*, que asigna un numero entero arbitrario a cada categoría. No obstante, para atributos nominales como *occupation* o *native-country*, esta técnica introduce un **sesgo de orden natural inexistente**. Si se utilizara una codificación entera simple, un modelo de ML (especialmente aquellos basados en distancias o pesos) interpretaría erróneamente que una categoría con valor 3 es "superior.º "mas distante.ª una con valor 1. Este orden artificial distorsiona la realidad de los datos nominales y puede degradar significativamente la precisión de los modelos.

2.1.3 Algoritmos con soporte categórico nativo vs Transformación

Es importante destacar que existen algoritmos basados en arboles de decisión (como *Random Forest*) o *XGBoost*) que pueden manejar atributos categóricos mediante lógicas en sus nodos. Sin embargo, para realizar un estudio comparativo, o para utilizar arquitecturas de DL, se debe realizar una estandarización mediante técnicas de *encoding*. Este trabajo explora tres enfoques distintos para resolver este desafió: *One-Hot Encoding*, *Count Encoding* y *Hashing Encoding*.

2.2 One-Hot Encoding (OHE)

El *One-Hot Encoding* es una de las técnicas de transformación mas utilizadas para el tratamiento de variables categóricas nominales, debido a su sencillez y compatibilidad con la mayoría de los algoritmos de aprendizaje automático. Su principio se basa en la eliminación de cualquier relación de orden mediante la binarización de los niveles de cada atributo.

2.2.1 Definición Formal

Matemáticamente, el *One-Hot Encoding* puede definirse como una función de mapeo ϕ que proyecta un nivel categórico en un espacio vectorial binario de dimensión k, donde k es la cardinalidad del atributo (número de niveles únicos).

Sea $\mathcal{C} = \{c_1, c_2, \ldots, c_k\}$ el conjunto de todos los niveles posibles de una variable categórica. La función $\phi : \mathcal{C} \to \{0,1\}^k$ asigna a cada categoría c_i un vector canónico $\mathbf{e}_i \in \mathbb{R}^k$:

$$\phi(c_i) = \mathbf{e}_i = (0, \ldots, 0, \underbrace{1}_{i\text{-ésima pos.}}, 0, \ldots, 0) \tag{2.1}$$

De esta manera, para cualquier instancia del conjunto de datos que pertenezca a la categoría c_i, la representación resultante es un vector de longitud k donde todas sus componentes son nulas, a excepción de la posición i, que toma el valor unitario. Esta propiedad garantiza que todos los vectores resultantes sean ortogonales entre sí, asegurando que el modelo no interprete cercanías o jerarquías espaciales erróneas entre etiquetas nominales.

2.2.2 Implementación e Impacto en la Dimensionalidad

En este trabajo, se implementó la función de OHE sobre las 8 variables categóricas del *dataset*. La aplicación de esta técnica generó una **explosión de dimensionalidad**.

El *dataset* original, que contaba con 14 atributos predictivos, se expandió a un total de **106 columnas** tras la codificación. El tamaño final del espacio de características D_{final} tras el proceso de binarización puede calcularse como:

$$D_{final} = D_{num} + \sum_{j=1}^{N} k_j \tag{2.2}$$

Donde D_{num} representa las variables numéricas originales y k_j la cardinalidad de la j-ésima variable categórica. En nuestro caso, este incremento exponencial se atribuye principalmente a variables como *native-country* ($k = 41$) y *occupation* ($k = 14$). Como resultado, se obtiene una matriz de diseño altamente dispersa (*sparse matrix*), lo cual aumenta los requerimientos de memoria y la complejidad computacional para los algoritmos de aprendizaje posteriores.

2.3 Count Encoding

El *Count Encoding* es una técnica de transformación que captura la importancia estadística de cada categoría dentro del conjunto de datos. A diferencia del OHE, este método no expande el espacio de características, manteniendo una correspondencia de 1:1 entre las variables originales y las transformadas.

2.3.1 Mecánica de Transformación y Definición Formal

La técnica consiste en reemplazar cada etiqueta categórica por el numero total de apariciones (frecuencia absoluta) de dicha etiqueta en el *dataset*. Sea X un atributo categórico y $\mathcal{C} = \{c_1, c_2 \ldots, c_k\}$ el conjunto de sus niveles. Definimos la función de transformación T como:

$$T(c_i) = \sum_{j=1}^{m} \mathbb{I}(x_j = c_i) \tag{2.3}$$

Donde m es el numero total de registros e $\mathbb{I}$ es la función indicatriz que toma el valor 1 si el registro x_j coincide con la categoría c_i, y 0 en caso contrario.

2.3.2 Frecuencia Relativa Normalizada

Se implemento una variante de **Count Encoding Normalizado**, la cual consiste en una función de transformación T_{norm} que se define como la probabilidad empírica de la categoría:

$$T_{norm}(c_i) = \frac{\sum_{j=1}^{m} \mathbb{I}(x_j = c_i)}{m} \tag{2.4}$$

Donde m es el tamaño total del *dataset*. El resultado es un espacio de características donde cada valor esta acotado en el intervalo $[0, 1]$.

2.3.3 Implementación y e Impacto en el Dataset

El impacto principal de esta técnica en el *Adult Income Dataset* fue la **preservación de la dimensionalidad original**. Tras la transformación, el dataset mantuvo sus **14 atributos predictivos**.

2.4 Hashing Encoding

El *Hashing Encoding* es una técnica de transformacion que utiliza funciones de dispersión (*hashing*) para mapear niveles categóricos en un espacio vectorial de dimensión fija y predefinida. A diferencia del *One-Hot Encoding*, el número de columnas resultantes no depende de la cardinalidad de los atributos, sino de un hiperparámetro que permite controlar directamente la dimensionalidad del espacio de características resultantes.

2.4.1 Definición Formal y Proceso de Hash (MurmurHash3)

El *Hashing Encoding* transforma un nivel categórico c en un espacio vectorial de dimensión n mediante una función de dispersión compuesta. El proceso se divide en tres etapas matemáticas: la generación del valor de hash, la mezcla de bits (*mixing*) y la proyección al espacio de características.

Algoritmo de Dispersión

En este trabajo se utiliza el algoritmo **MurmurHash3**, una función de hash no criptográfica que destaca por su baja tasa de colisión. Dado un nivel categórico c (tratado como una secuencia de bytes), el proceso para obtener el valor entero $h(c)$ se define mediante las siguientes transformaciones iterativas:

1. **Inicialización:** Se define un valor inicial o *seed* (s) y constantes de mezcla $c_1 = 0\text{xcc9e2d51}$, $c_2 = 0\text{x1b873593}$. 2. **Procesamiento por bloques:** Para cada bloque de datos k de la cadena, se aplican rotaciones y multiplicaciones:

$$\begin{cases} k \leftarrow k \cdot c_1 \\ k \leftarrow (k \ll 15) \mid (k \gg 17) \text{ (Rotación a la izquierda)} \\ k \leftarrow k \cdot c_2 \\ h \leftarrow h \oplus k \\ h \leftarrow (h \ll 13) \mid (h \gg 19) \\ h \leftarrow h \cdot 5 + 0\text{xe6546b64} \end{cases} \tag{2.5}$$

3. **Finalización (Avalanche):** Para asegurar que cambios mínimos en la entrada generen cambios drásticos en la salida, se aplica una función de mezcla final (*finalizer*):

$$\begin{aligned} h &\leftarrow h \oplus (\text{longitud de } c) \\ h &\leftarrow h \oplus (h \gg 16) \cdot 0\text{x85ebca6b} \\ h &\leftarrow h \oplus (h \gg 13) \cdot 0\text{xc2b2ae35} \\ h &\leftarrow h \oplus (h \gg 16) \end{aligned} \tag{2.6}$$

Proyección al Espacio de Características

Una vez obtenido el valor entero $h(c)$, la transformación final $\mathcal{H}(c)$ hacia el vector de características de dimensión n (donde $n \in \{8, 16, 32\}$ en nuestro experimento) se realiza mediante la operación módulo:

$$\mathcal{H}(c) = |h(c)| \pmod{n} \tag{2.7}$$

Finalmente, el vector resultante $\mathbf{V} \in \{0, 1\}^n$ activa la posición correspondiente:

$$\mathbf{V}_i = \begin{cases} 1 & \text{si } \mathcal{H}(c) = i \\ 0 & \text{en otro caso} \end{cases} \tag{2.8}$$

Este proceso garantiza que cualquier entrada de texto, sin importar su longitud o complejidad, sea mapeada a una de las n dimensiones de forma pseudoaleatoria y uniforme, permitiendo la reducción de las 106 columnas originales a los espacios de 15, 23 o 39 columnas analizados en este estudio.

2.4.2 Implementación Experimental e Impacto en la Dimensionalidad

Se evaluó el impacto de esta técnica sobre las 8 variables categóricas del *Adult Income Dataset* mediante tres configuraciones de dimensionalidad fija. El uso de *Hashing Encoding* permitió mitigar drásticamente la explosión de dimensionalidad observada con el método OHE (106 columnas), permitiendo un control preciso sobre el ancho de la matriz de entrada.

Para el desarrollo experimental, se generaron tres versiones del conjunto de datos, cuya estructura final se detalla a continuación:

1. **Configuración de 8 componentes:** El *dataset* se redujo a un total de **15 columnas**. Esta versión representa la compresión más agresiva, orientada a minimizar el costo computacional.

2. **Configuración de 16 componentes:** El *dataset* resultó en un total de **23 columnas**. Esta configuración busca un equilibrio entre la reducción de dimensiones y la preservación de la varianza de los datos.

3. **Configuración de 32 componentes:** El *dataset* final cuenta con **39 columnas**. Esta variante ofrece el mayor espacio para la función de hash, reduciendo significativamente la probabilidad de colisiones.

Independientemente del número de componentes de hash seleccionados, la estructura interna de cada *dataset* mantiene la integridad de los datos originales, componiéndose de:

- n columnas generadas por la función de hash (denominadas de `col_0` a `col_n-1`).
- 6 atributos numéricos originales (*age, fnlwgt, educational-num, capital-gain, capital-loss, hours-per-week*).
- 1 variable objetivo binaria (*income*).

2.4.3 Análisis de Riesgos: El Fenómeno de la Colisión

A pesar de sus beneficios en términos de eficiencia, el *Hashing Encoding* introduce un riesgo estadístico denominado **colisión de hash**. Una colisión ocurre cuando dos niveles categóricos distintos ($c_1 \neq c_2$) producen el mismo índice de salida:

$$h(c_1) \equiv h(c_2) \pmod{n} \tag{2.9}$$

En este escenario, el modelo pierde la capacidad de distinguir entre ambas categorías, lo que equivale a introducir ruido en los datos.

2.5 Análisis Comparativo de las Técnicas de Codificación

Técnica	Columnas Finales	Tipo de Dato	Riesgo Principal
Dataset Original	14	Mixto	No procesable
One-Hot Encoding	106	Binario	Explosión dimensional
Count Encoding	14	Numérico	Colisión de frecuencias
Hash-8	15	Binario/Hash	Colisión alta
Hash-16	23	Binario/Hash	Colisión moderada
Hash-32	39	Binario/Hash	Colisión baja

Tabla 2.1: Comparativa del impacto de las técnicas de encoding en la dimensionalidad del dataset Adult Income.

Capítulo 3

Resultados y discusión

Capítulo 4

Conclusiones

Bibliografía